

CONTEXTE APPLICATIF GLOBAL & CAHIER DES CHARGES

1. VISION GÉNÉRALE DU PROJET

Le projet consiste à développer une **plateforme logicielle interne de centralisation, de gestion, d'exploration et de visualisation de données multi-formats et multi-modèles**.

Initialement conçue pour du **data scoring bancaire** (analyse de flux de transactions, relations clients/comptes, dépendances d'entités), la plateforme intègre un second cas d'usage de **Social Data Engineering** : la collecte, le traitement, la modélisation et l'analyse prédictive des réseaux de relations sociales (appliqué ici aux données de réseaux sociaux comme Facebook) pour identifier et classifier les connexions relationnelles réellement significatives ("les vrais amis") grâce à l'Intelligence Artificielle.

2. ARCHITECTURE TECHNIQUE & MODÉLISATION MULTI-MODÈLE

L'infrastructure logicielle repose sur une architecture de stockage hybride (Multi-Modèle) qui fait coexister deux bases de données :

- **PostgreSQL (Modèle Relationnel)** : Gère les données d'infrastructure (comptes utilisateurs du système, logs, métadonnées des datasets, politiques de permissions et d'accès généraux) et l'importation initiale de fichiers plats (formats types CSV).
- **Neo4j (Modèle Graphe)** : Gère le stockage des structures relationnelles complexes (flux financiers, réseaux sociaux, arbres de dépendances) pour permettre des calculs de traversée de graphes, de voisinages et de connectivité en temps réel.

PIPELINE ETL DE DONNÉES GRAPHE (EXEMPLE FACEBOOK) :

1. **Collecte** : Récupération automatisée des données brutes (amis, interactions, profils, commentaires, mentions J'aime, publications, partages, groupes et événements communs).
 2. **Nettoyage & Structuration** : Traitement des données bruitées, déduplication, gestion des valeurs manquantes et des anomalies, puis modélisation sous forme de nœuds et d'arêtes.
 3. **Schéma Graphe ciblé** :
 - **Nœuds** : Utilisateur , Publication , Groupe , Événement , Page .
 - **Relations (Arêtes)** : FRIEND_OF , COMMENTED , LIKED , TAGGED_IN , MEMBER_OF . Les relations possèdent des propriétés (poids relationnel, date, fréquence).
-

3. ENGINE DE MACHINE LEARNING & SCORING RELATIONNEL

Le module d'analyse prédictive doit entraîner et exécuter un modèle de Machine Learning capable de calculer la force intrinsèque d'une relation.

- **Variables (Features) d'Entrée** : Fréquence des interactions, réciprocité des échanges, ancienneté de la relation, proximité sociale, centralité du nœud, appartenance à des communautés communes, similarité comportementale, centres d'intérêt partagés, et stabilité des interactions au fil du temps.
- **Outputs Attendus du Modèle** :
 - Un **Score relationnel** numérique précis (ex: 0.92 pour une relation forte, 0.15 pour une relation faible).
 - Un **Classement dynamique** des entités (classement des connexions par ordre d'importance).
 - Une **Classification automatique** par catégories relationnelles (Cercles proches, connaissances, profils inactifs).
 - Des recommandations analytiques automatisées.

4. EXPÉRIENCE UTILISATEUR (UI/UX) & DESIGN SYSTEM

4.1 PERSONAS CIBLES

L'interface doit impérativement répondre aux exigences ergonomiques de 4 profils distincts :

1. **Julie (Expert Data - Persona Principal)** : 33 ans, Data Analyst bancaire. Elle a besoin d'importer des fichiers facilement, de filtrer instantanément de larges tableaux, d'accéder à des statistiques descriptives macro et de comprendre visuellement les corrélations pour gagner du temps.
2. **David (Chercheur en IA - Persona Secondaire)** : 29 ans. Il analyse les connexions complexes, explore les graphes, cherche des chemins, calcule les centralités et a besoin d'outils avancés de détection de communautés et d'anomalies.
3. **Professeure Malie (Professeur en Université - Moins adapté)** : Cherche un outil visuel pédagogique, simple à projeter, mettant en avant des indicateurs clés lisibles et des graphiques clairs pour illustrer ses cours.
4. **Sarah (Étudiante - Moins adapté)** : Découvre la data science ; a besoin d'une courbe d'apprentissage douce, d'une interface guidée, claire, rassurante et sans jargon excessif.

4.2 ARCHITECTURE DE NAVIGATION GLOBALE (NAVIGATION HYBRIDE)

La navigation doit respecter scrupuleusement la structure logique suivante :

- **Menu Principal Latéral** : Panneau rétractable (contrôlé par un bouton ≡ Hamburger) contenant l'accès direct aux 6 modules applicatifs :
 1. `Datasets` (Gestion, imports, historiques)
 2. `Exploration` (Fouilles de données)
 3. `Analyses` (Calculs de métriques)
 4. `Visualisations` (Graphiques et réseaux)

5. Administration (Gestion système)

6. Paramètres (Configurations)

- **Barre d'En-tête (Header)** : Intègre une **Barre de recherche globale** capable de scanner instantanément n'importe quel dataset, utilisateur, nœud ou entité spécifique du système.
- **Fil d'Ariane (Breadcrumb)** : Présent systématiquement sur les pages de niveau 2+ pour l'orientation utilisateur (Exemple : `Accueil > Datasets > Importer un dataset`).
- **Onglets Secondaires (Sub-tabs)** : Utilisés pour basculer de perspective à l'intérieur d'un même espace de travail sans perte de contexte :
 - *Dans Datasets* : Tous les datasets | Importer | Détails d'un dataset
 - *Dans Exploration* : Vue Tableau | Vue Graphe
 - *Dans Analyses* : Statistiques descriptives | Détection d'anomalies | Analyse relationnelle | Rapports

4.3 CHARTES GRAPHIQUE & DESIGN SYSTEM

- **Palette de Couleurs** :
 - `#111827` (Ink Black) - Texte principal, titres et éléments sombres.
 - `#2563EB` (Royal Blue) - Couleur d'action principale, focus, liens et accents.
 - `#F9FAFB` (Bright Snow) - Fond d'écran, surfaces claires et conteneurs.
 - `#9CA3AF` (Cool Steel) - Bordures, textes secondaires et états désactivés.
 - **Typographies Autorisées** : *Inter*, *DM Sans*, ou *Roboto*.
 - **Système de Grille & Espacements** : Alignement strict basé sur des **multiples de 8px** uniquement (`8px` , `16px` , `24px` , `32px` , `48px` , `64px`). Tout composant ou conteneur doit respecter cette règle de marge et de padding.
-

5. SPÉCIFICATIONS DES COMPOSANTS MAJEURS

5.1 VUE TABLEAUX (DONNÉES TABULAIRES / RELATIONNELLES)

- Affichage sous forme de tableaux de données paginés et scrollables.
- Moteur de filtres multicritères en colonnes et tris ascendants/descendants.
- Calcul automatique d'indicateurs de qualité de données (Taux de valeurs manquantes, distributions, alertes d'anomalies).

5.2 VUE GRAPHES (RÉSEAUX COMPLEXES)

- Affichage et rendu dynamique (Ressorts/Forces) interactif des nœuds et des arêtes.
 - Interactions requises : Déplacement manuel des nœuds, Zoom / Pan, surbrillance au survol.
 - Outils d'exploration : Recherche textuelle de nœuds, filtrage temporel des relations via un slider, filtrage par type d'interaction, coloration automatique des nœuds selon leur groupe/communauté, affichage des propriétés et scores des relations au clic, et déploiement progressif des voisinages.
 - *Technologies applicables* : Cytoscape.js, D3.js, Sigma.js, ou Vis Network.
-

6. INSTRUCTIONS ET DIRECTIVES DE CONCEPTION POUR L'IA

Lorsque je te demande de générer du code, des maquettes, des scripts ou de la documentation, tu dois respecter rigoureusement les contraintes suivantes :

1. **Compatibilité Multi-Modèle** : Assure-toi que les propositions techniques prennent en compte la dualité SQL (PostgreSQL) et Graphe (Neo4j).
2. **Fidélité UI/UX** : Applique strictement le Design System (palette de couleurs, typographies, règles des multiples de 8px pour les espacements) et la hiérarchie de navigation (Menu latéral + Fil d'ariane + Onglets secondaires).

3. **Centricité Utilisateur** : Justifie tes choix de conception en fonction des besoins des personas (notamment la simplicité d'import pour Julie et la profondeur analytique des graphes pour David).
4. **Vocabulaire Data/ML** : Utilise les termes exacts issus de l'analyse relationnelle (degré de centralité, détection de communautés, score relationnel, arêtes pondérées).

sitemap (arborescence):



